

PUC-RJ

Curso: Ciência de Dados e Analytics

Disciplina: Sprint: Engenharia de Dados

Aluno: Otávio Braz Ribeiro Junior

MVP Análise de Filmes (IMDb)

Base de Dados

A base de dados utilizada neste MVP foi obtida a partir do IMDb (Internet Movie Database), por meio dos IMDb Non-Commercial Datasets, disponibilizados oficialmente para uso pessoal e não comercial. O IMDb reúne informações e avaliações fornecidas por usuários sobre filmes de diferentes gêneros e períodos.

O conjunto de dados contém atributos como gênero, ano de lançamento, duração, nota média e número de votos, permitindo analisar tanto a avaliação quanto a popularidade dos filmes. Essas informações são adequadas para investigar fatores associados a melhores avaliações do público.

Por se tratar de dados públicos destinados a fins educacionais, foi realizada uma análise de qualidade dos dados antes das etapas analíticas, incluindo a identificação de valores ausentes e possíveis inconsistências.

Problema de Negócio


Quais características estão associadas a filmes com melhor avaliação do público?

Perguntas de Pesquisa

- Quais gêneros têm maior média de avaliação no IMDb?
- Existe uma relação entre o ano de lançamento e a avaliação do filme?
- A duração do filme impacta sua avaliação?
- Filmes com mais votos têm melhores notas?
- Quais gêneros concentram os filmes mais populares (com maior número de votos)?

Download dos Arquivos

Foi feito o download do Dataset contendo os dados básicos dos filmes “title.basics” e das avaliações “title.ratings”, diretamente do site do IMDB: [IMDb Data Files Download](#). A licença dos arquivos é do tipo Non-Commercial. Posteriormente, os arquivos foram carregados no Databricks, conforme print:



Leitura dos Datasets

```
df_basics = spark.read.csv(  
    "dbfs:/Volumes/workspace/mvp/filmes_imdb/title.basics.tsv.gz",  
    sep="\t",  
    header=True,  
    inferSchema=True  
)  
  
df_ratings = spark.read.csv(  
    "dbfs:/Volumes/workspace/mvp/filmes_imdb/title.ratings.tsv.gz",  
    sep="\t",  
    header=True,  
    inferSchema=True  
)
```

Resultado

```
▼ df_basics: pyspark.sql.connect.dataframe.DataFrame  
  tconst: string  
  titleType: string  
  primaryTitle: string  
  originalTitle: string  
  isAdult: integer  
  startYear: string  
  endYear: string  
  runtimeMinutes: string  
  genres: string  
  
▼ df_ratings: pyspark.sql.connect.dataframe.DataFrame  
  tconst: string  
  averageRating: double  
  numVotes: integer
```

Estrutura dos Dados

Os dados do IMDb foram carregados com sucesso na plataforma Databricks, permitindo a verificação da estrutura dos conjuntos de dados utilizados. O conjunto `title.basics` reúne as principais características dos filmes, como o identificador único (`tconst`), o tipo do título, o título principal, o título original, a indicação de conteúdo adulto, o ano de lançamento, a duração em minutos e os gêneros. Já o conjunto `title.ratings` contém as informações relacionadas à avaliação do público, incluindo a nota média atribuída aos filmes e o número de votos recebidos.


A correta identificação dessas colunas confirma que os dados foram carregados adequadamente e estão prontos para as etapas de transformação.

Modelo de Dados

Os dados foram organizados em um modelo relacional simples, composto por duas tabelas: uma contendo as características dos filmes e outra contendo as informações de avaliação do público. As tabelas são relacionadas por meio de uma chave comum (`tconst`), que identifica de forma única cada filme no conjunto de dados.

Transformação dos Dados

Foi realizada a filtragem para considerar apenas filmes, excluindo séries e demais subtipos. Além disso, foram selecionadas as colunas relevantes para o escopo do trabalho: `genres`, `startYear`, `runtimeMinutes`, `averageRating`, `numVotes`.



```
from pyspark.sql.functions import col

df_filmes_tratado = (
    df_basics
    .filter(col("titleType") == "movie")
    .select(
        "tconst",
        "primaryTitle",
        "startYear",
        "runtimeMinutes",
        "genres"
    )
)
```

df_filmes_tratado: pyspark.sql.connect.dataframe.DataFrame

tconst:	string
primaryTitle:	string
startYear:	string
runtimeMinutes:	string
genres:	string

Verificando a Consistência dos Dados

```
df_basics.printSchema()
```

```
root
|-- tconst: string (nullable = true)
|-- titleType: string (nullable = true)
|-- primaryTitle: string (nullable = true)
|-- originalTitle: string (nullable = true)
|-- isAdult: integer (nullable = true)
|-- startYear: string (nullable = true)
|-- endYear: string (nullable = true)
|-- runtimeMinutes: string (nullable = true)
|-- genres: string (nullable = true)
```

A verificação do esquema dos dados confirmou que as colunas do conjunto `title.basics` foram corretamente reconhecidas pela plataforma, incluindo identificador do filme, tipo do título, ano de lançamento, duração e gêneros. Essa validação garante que os dados estão estruturados de forma adequada para as etapas seguintes de transformação e análise.

Verificação de Valores Nulos

Criando a View

```
#Criando Views
df_filmes_tratado.createOrReplaceTempView("filmes")
df_ratings.createOrReplaceTempView("ratings")
```

Comando	Iniciado em	Duração	Linhas lidas	Bytes lidos	Bytes escritos
L4 > df_ratings.create...	16 de dez. de 2025, 21:09	71 milissegund	0	0 B	0 B
L3 > df_filmes_tratado...	16 de dez. de 2025, 21:09	98 milissegun	0	0 B	0 B

Verificando Nulos da Tabela Filmes

Conforme indicado no print a pesquisa não retornou valores nulos.


```
%sql
-- Verificando Nulos - Tabela Filmes

SELECT
  COUNT(*) AS total_registros,
  SUM(CASE WHEN startYear IS NULL THEN 1 ELSE 0 END) AS startYear_nulos,
  SUM(CASE WHEN runtimeMinutes IS NULL THEN 1 ELSE 0 END) AS runtime_nulos,
  SUM(CASE WHEN genres IS NULL THEN 1 ELSE 0 END) AS genres_nulos
FROM filmes;
```

Tabela	total_registros	startYear_nulos	runtime_nulos	genres_nulos
1	734427	0	0	0

Verificando Nulos na Tabela Ratings

Conforme print, a pesquisa não retornou valores nulos.



```
%sql
-- Verificando Nulos - Tabela Rating

SELECT
  COUNT(*) AS total_registros,
  SUM(CASE WHEN averageRating IS NULL THEN 1 ELSE 0 END) AS rating_nulos,
  SUM(CASE WHEN numVotes IS NULL THEN 1 ELSE 0 END) AS votos_nulos
FROM ratings;
```


> [Ver desempenho \(1\)](#) Otimiza

> `_sqldf: pyspark.sql.connect.dataframe.DataFrame = [total_registros: long, rating_nulos: long ... mais 1 campo]`

	total_registros	rating_nulos	votos_nulos
1	1611810	0	0

Verificando a Quantidade de Filmes

O Dataset reúne informações de 734.427 filmes.



```
%sql
--Verificando a quantidade de filmes

SELECT COUNT(*) AS total_filmes
FROM filmes;
```

> [Ver desempenho \(1\)](#) Otimizar

> `_sqldf: pyspark.sql.connect.dataframe.DataFrame = [total_filmes: long]`


	total_filmes
1	734427

Análise do Problema

Utilizaremos pesquisas em SQL para responder as seguintes perguntas propostas.

1. Quais gêneros têm maior média de avaliação no IMDb?

A consulta retornou médias de avaliação para 1.273 combinações distintas de gêneros. Esse resultado ocorre porque, no IMDb, os filmes podem ser classificados simultaneamente em mais de um gênero, gerando diversas combinações possíveis. Dessa forma, a análise direta por gênero torna-se menos interpretável, uma vez que os resultados refletem combinações específicas e não categorias isoladas. Para uma análise mais precisa, seria necessário agrupar ou normalizar os gêneros, seja por meio de pré-processamento dos dados ou por técnicas mais avançadas, como métodos de aprendizado de máquina, a fim de identificar padrões mais consistentes.



```
%sql
-- Quais gêneros tem maior nota de avaliação

SELECT
  f.genres,
  AVG(r.averageRating) AS media_avaliacao,
  COUNT(*) AS quantidade_filmes
FROM filmes f
JOIN ratings r
  ON f.tconst = r.tconst
GROUP BY f.genres
ORDER BY media_avaliacao DESC;
```

> [Ver desempenho \(1\)](#) Otimizar

1,273 linhas

16.62s de runtime

Atualizada há 11 minutos

Este resultado é armazenado como `_sqlf` e pode ser usado em outras células Python e SQL.

2. Existe uma relação entre o ano de lançamento e a avaliação do filme?

A análise inicial retornou uma tabela com 132 linhas correspondendo aos anos de lançamento dos filmes.

Para uma melhor visualização o resultado foi agrupado em décadas. O resultado possibilitou inferir que desde as décadas 1890 até 2020 a avaliação dos filmes tem melhorado de forma gradual, com pequeno recuo entre as décadas de 60 e 90. Mas de modo geral, pode-se inferir que os filmes mais recentes recebem maiores notas.

Há 2 minutos (16s)

13

SQL

```

%sql
--Relação do ano de lançamento com avaliação por década

SELECT
    FLOOR(CAST(f.startYear AS INT) / 10) * 10 AS decada,
    ROUND(AVG(r.averageRating), 2) AS media_avaliacao,
    COUNT(*) AS quantidade_filmes
FROM filmes f
JOIN ratings r
    ON f.tconst = r.tconst
WHERE f.startYear IS NOT NULL
    AND f.startYear <> '\\N'
GROUP BY FLOOR(CAST(f.startYear AS INT) / 10) * 10
ORDER BY decada;

```

	^{1.º} decada	1.2 media_avaliacao	^{1.º} quantidade_filmes
1	1890	2.81	18
2	1900	3.56	162
3	1910	5.78	1960
4	1920	6	4004
5	1930	6.1	9319
6	1940	6.19	9241
7	1950	6.19	13133
8	1960	6.1	17726
9	1970	5.94	23530
10	1980	6	26262
11	1990	6.05	27557
12	2000	6.21	48067
13	2010	6.24	94675
14	2020	6.34	61062

3. A duração do filme impacta sua avaliação?

Os filmes foram agrupados em 4 faixas de duração: até 60 minutos, entre 60 a 89 minutos, entre 90 a 119 minutos e entre 120 a 149 minutos.

A análise por faixas de duração indica que não há uma relação direta entre o tempo de duração do filme e sua avaliação média. As notas permanecem relativamente próximas entre as diferentes faixas analisadas, sugerindo que a duração, isoladamente, não é um fator determinante para a avaliação do público.

```

%sql
--Relação da duração do filme com a nota obtida

SELECT
CASE
WHEN try_cast(f.runtimeMinutes AS INT) < 60 THEN 'Até 60 min'
WHEN try_cast(f.runtimeMinutes AS INT) BETWEEN 60 AND 89 THEN '60-89 min'
WHEN try_cast(f.runtimeMinutes AS INT) BETWEEN 90 AND 119 THEN '90-119 min'
WHEN try_cast(f.runtimeMinutes AS INT) BETWEEN 120 AND 149 THEN '120-149 min'
ELSE '150 min ou mais'
END AS faixa_duracao,
ROUND(AVG(r.averageRating), 2) AS media_avaliacao,
COUNT(*) AS quantidade_filmes
FROM filmes f
JOIN ratings r
ON f.tconst = r.tconst
WHERE try_cast(f.runtimeMinutes AS INT) IS NOT NULL
GROUP BY
CASE
WHEN try_cast(f.runtimeMinutes AS INT) < 60 THEN 'Até 60 min'
WHEN try_cast(f.runtimeMinutes AS INT) BETWEEN 60 AND 89 THEN '60-89 min'
WHEN try_cast(f.runtimeMinutes AS INT) BETWEEN 90 AND 119 THEN '90-119 min'
WHEN try_cast(f.runtimeMinutes AS INT) BETWEEN 120 AND 149 THEN '120-149 min'
ELSE '150 min ou mais'
END
ORDER BY faixa_duracao;

```

	A ₀ faixa_duracao	1.2 media_avaliacao	A ₃ quantidade_filmes
1	120-149 min	6.51	26510
2	150 min ou mais	6.73	8750
3	60-89 min	6.04	112276
4	90-119 min	6.1	138078
5	Até 60 min	6.68	17943

5 linhas | 16,18s de runtime

4. Filmes com mais votos têm melhores notas?

Os filmes foram agrupados em faixas de votos por ordens de magnitude, com o objetivo de reduzir a assimetria do dado e facilitar a interpretação dos resultados sem necessidade de gráficos. As faixas adotadas foram: até 100 votos, 100–999 votos, 1k–9k votos, 10k–99k votos e 100k votos ou mais. Observou-se uma leve correlação que indica que filmes mais populares obtêm notas mais altas.

```

%sql
--Relação entre quantidades de votos e nota

SELECT
CASE
WHEN r.numVotes < 100 THEN 'Até 100 votos'
WHEN r.numVotes BETWEEN 100 AND 999 THEN '100-999 votos'
WHEN r.numVotes BETWEEN 1000 AND 9999 THEN '1k-9k votos'
WHEN r.numVotes BETWEEN 10000 AND 99999 THEN '10k-99k votos'
ELSE '100k votos ou mais'
END AS faixa_votos,
ROUND(AVG(r.averageRating), 2) AS media_avaliacao,
COUNT(*) AS quantidade_filmes
FROM ratings r
JOIN filmes f
ON r.tconst = f.tconst
WHERE r.numVotes IS NOT NULL
GROUP BY
CASE
WHEN r.numVotes < 100 THEN 'Até 100 votos'
WHEN r.numVotes BETWEEN 100 AND 999 THEN '100-999 votos'
WHEN r.numVotes BETWEEN 1000 AND 9999 THEN '1k-9k votos'
WHEN r.numVotes BETWEEN 10000 AND 99999 THEN '10k-99k votos'
ELSE '100k votos ou mais'
END
ORDER BY faixa_votos;

```


_sqldf: pyspark.sql.connect.dataframe.DataFrame = [faixa_votos: string, media_avaliacao: double ...]

	A ^B faixa_votos	1.2 media_avaliacao	1 ² ₃ quantidade_filmes
1	100k votos ou mais	7	2654
2	100–999 votos	5.76	94812
3	10k–99k votos	6.47	9502
4	1k–9k votos	6.12	35142
5	Até 100 votos	6.36	194639

5. Quais gêneros concentram os filmes mais populares (com maior número de votos)?

Considerando a grande variedade de gêneros foi utilizada a seguinte estratégia para construção da query : juntar filmes e avaliações, soma o total de votos por gênero, retorna 10 gêneros mais populares.

Os filmes mais populares concentram-se em gêneros como Ação, Aventura, Drama e Comédia, indicando que essas categorias despertam maior interesse e engajamento do público no IMDb.



```

%sql
--Quais gêneros concentram os filmes mais populares (com maior número de votos)?

SELECT
  f.genres,
  SUM(r.numVotes) AS total_votos,
  COUNT(*) AS quantidade_filmes
FROM filmes f
JOIN ratings r
  ON f.tconst = r.tconst
WHERE f.genres IS NOT NULL
GROUP BY f.genres
ORDER BY total_votos DESC
LIMIT 10;

```

	A ^B genres	1 ² ₃ total_votos	1 ² ₃ quantidade_filmes
1	Action,Adventure,Sci-Fi	57978888	377
2	Drama	46325300	56747
3	Comedy,Drama,Romance	39544563	5084
4	Adventure,Animation,Come...	37780645	826
5	Action,Crime,Drama	34674969	3551
6	Comedy	33526157	26752
7	Comedy,Drama	32982316	10672
8	Action,Adventure,Fantasy	32686860	495
9	Drama,Romance	30799696	10162
10	Action,Adventure,Comedy	28779800	1265

Conclusão

Este trabalho teve como objetivo analisar quais características estão associadas a melhores avaliações e maior popularidade de filmes a partir de dados públicos do IMDb. Os resultados indicam que fatores como gênero, ano de lançamento, duração e número de votos apresentam diferentes níveis de associação com a avaliação do público.

Observou-se que filmes mais populares, medidos pelo número de votos, tendem a apresentar avaliações médias mais altas, sugerindo uma relação positiva entre engajamento do público e nota atribuída. Em relação à duração e ao ano de lançamento, os resultados não indicaram uma influência determinante sobre a avaliação, apontando que esses fatores, isoladamente, não explicam a variação das notas. Quanto aos gêneros, verificou-se que categorias amplamente consumidas, como Ação, Aventura, Drama e Comédia, concentram os filmes mais populares, embora não seja possível afirmar que um gênero específico garanta melhores avaliações.

Autoavaliação

Os objetivos definidos no início do trabalho foram atendidos de forma satisfatória. Foi possível utilizar a plataforma Databricks para realizar a carga dos dados do IMDb, organizar as informações e executar análises que permitiram responder às principais perguntas propostas sobre avaliação e popularidade dos filmes.

Durante o desenvolvimento do trabalho, a principal dificuldade esteve relacionada ao tratamento e à interpretação dos dados, especialmente no caso da variável de gêneros, que apresenta muitas combinações diferentes. Isso limitou análises mais detalhadas e exigiu o uso de abordagens mais simples para interpretação dos resultados.

Como continuidade, o trabalho poderia ser aprimorado com o uso de técnicas mais avançadas, como agrupamento de gêneros ou modelos de aprendizado de máquina, além da utilização de visualizações gráficas para aprofundar a análise. Ainda assim, o MVP cumpriu seu papel ao aplicar conceitos de pipeline de dados e análise em um conjunto de dados público.